Lab 2 Part 2 報告：Qwen3-4B LLM Compression

學號：315605019　　日期：2026-10-25

實作設定

四個 case 都有達到要求，下表是 `bash run.sh` 在一張 T4 上的輸出。

Case	方法	Compression Ratio	PPL
Base	FP16	0%	13.64
1	GPTQ INT4 g128 + gate_proj INT3 g128	75.58%	14.02
2	GPTQ INT3 g512	81.02%	15.49
3	Whitened SVD (MLP) + INT8	50.01%（SVD 20.88%）	20.80
4	結構化剪枝 MLP channel + GPTQ INT3 g512	85.23%（剪枝 22.20%）	18.33

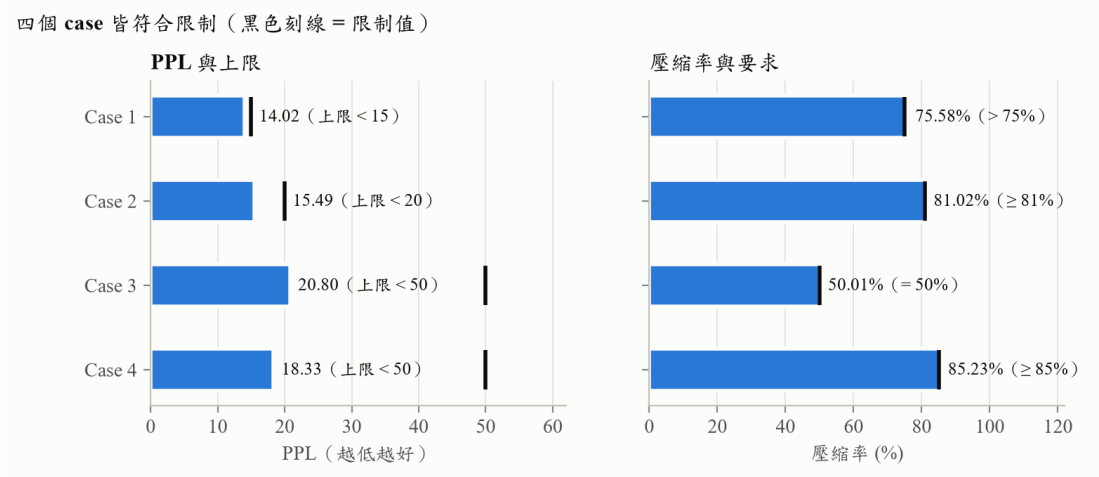


圖 1：四個 case 的 PPL 與壓縮率，黑色刻線為限制值

壓縮對象是 36 層的 q/k/v/o/gate/up/down_proj，共 3.633B 個參數。lm_head 和 embedding 共用權重，不列入計算。校正資料取 WikiText-2 train 的 128 段、每段 2048 token，沒有用到 test。

壓縮率依實際儲存需要的 bits 計算。量化的部分包含每個 group 的 fp16 scale 和 zero point；SVD 的部分包含兩個低秩矩陣量化後的大小；結構化剪枝因為矩陣直接變小，不需要額外存 mask。程式裡每個模組會記錄自己的 `_compressed_bits`，`compression_rate()` 再把它們加總。

GPTQ 是自己用 PyTorch 寫的，有 act-order 和 static groups，逐層依序量化。MSE clipping 會對每個 group 搜尋最佳的量化範圍。下表是幾種常用設定換算的 bits，各 case 的實際組成見圖 2。

配置	bits / weight	壓縮率
INT4 g128	4.156	74.0%
INT3 g128	3.148	80.3%
INT3 g512	3.037	81.02%
INT3 per-channel	3.007	81.2%
INT8 per-channel	8.006	50.0%

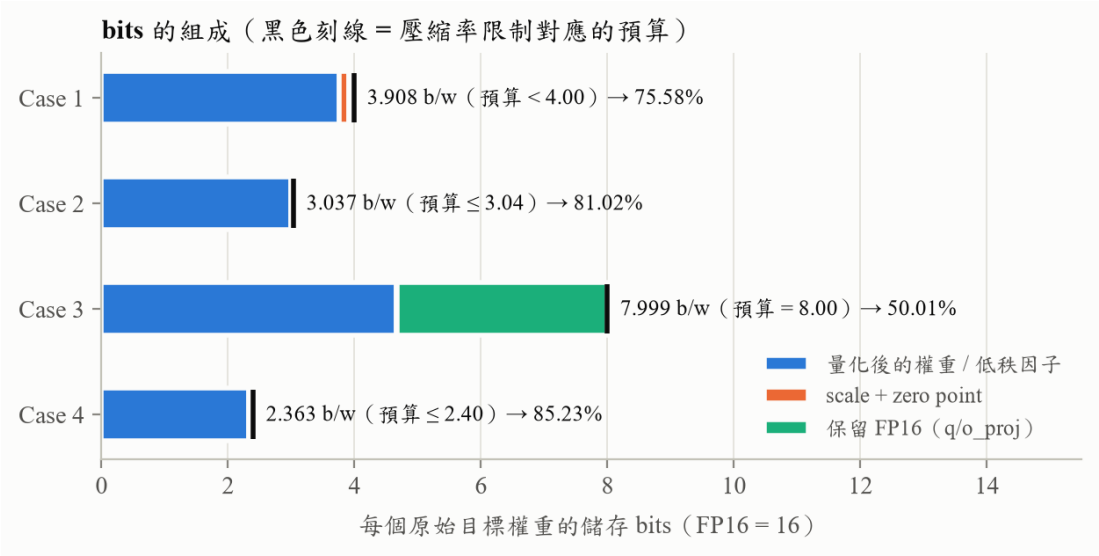


圖 2：各 case 每個原始權重的儲存 bits 組成

Case 1：> 75%，PPL < 15

Compression Strategy

使用 GPTQ 加 MSE clipping，壓縮全部目標層。gate_proj 用 INT3 g128，其餘用 INT4 g128，都是非對稱量化，平均 3.907 bits / weight。

Result

壓縮率 75.58%，PPL 14.02。

Analysis

INT4 g128 加上 scale 和 zero point 後是 4.156 bits，壓縮率只有 74.0%，所以至少要有約 16.5% 的參數降到 3-bit。我分別把每種 projection 降成 INT3 測試，gate_proj 對 PPL 的影響最小（見總結），所以選它。

MSE clipping 的幫助很明顯（圖 3）。全部 INT4 時，PPL 從 14.16 降到 13.84；加上 gate INT3 後，從 14.29 降到 14.02。最後的結果甚至比沒有 MSE 的全 INT4 還好。

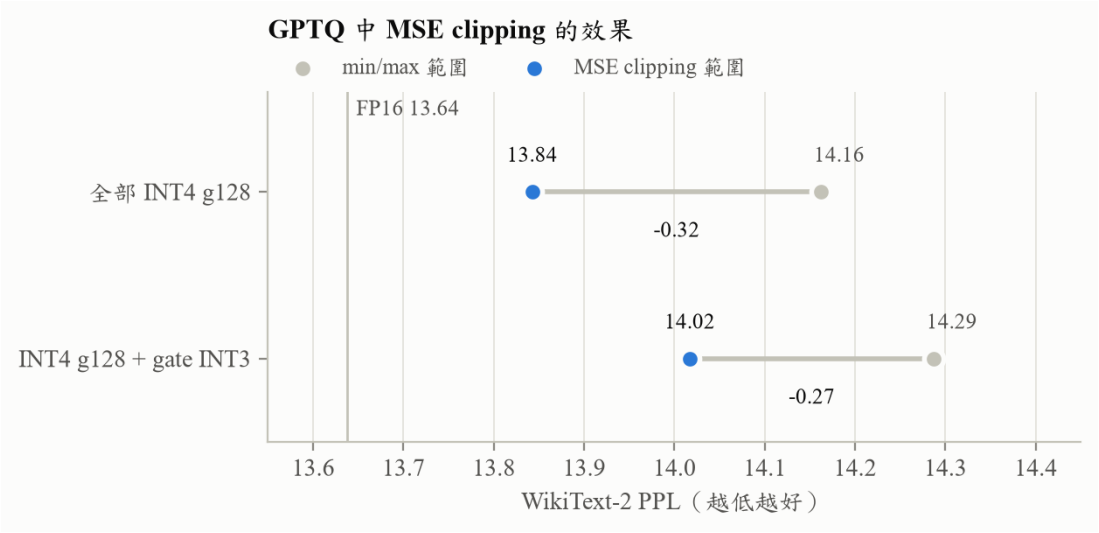


圖 3：GPTQ 中 MSE clipping 的效果

Case 2：≥ 81%，PPL < 20

Compression Strategy

全部目標層使用 GPTQ INT3、group size 512、非對稱量化，加上 MSE clipping，平均 3.037 bits / weight。

Result

壓縮率 81.02%，PPL 15.49。

Analysis

81% 的要求代表平均不能超過 3.04 bits。INT3 g128 是 3.148 bits，不夠；g256 搭配 8-bit scale 是 3.043 bits，也差一點。INT3 per-channel 是 3.007 bits，壓縮率夠，但 PPL 是 22.89，超過上限。g512 是能過 81% 的最小 group size，比 per-channel 只多 0.03 bits，PPL 就降到 15.49。可見在 3-bit 時，group 的粒度影響很大。

Case 3：SVD ≥ 20%，Overall = 50%，PPL < 50

Compression Strategy

對 gate/up/down_proj 做 whitened SVD（SVD-LLM 的做法）：先用校正資料算出輸入的二階矩 XX^T，取 Cholesky 因子 S，再對 W·S 做 SVD 截斷。這樣丟掉的部分是對輸出影響最小的方向。36 層共用 rank 1455，由程式二分搜尋，讓整體壓縮率最接近且不低於 50%。

分解出來的兩個矩陣用 INT8 per-row 量化，k/v_proj 用 INT8，q/o_proj 保留 FP16。

Result

整體壓縮率 50.01%，其中 SVD 部分 20.88%，PPL 20.80。

Analysis

rank r 的低秩分解需要 r(m + n) 個參數，只有在 r < mn / (m + n) 時才會比原矩陣小。以 9728 × 2560 的矩陣來說，上限是 2027；r = 1455 時保留 71.8% 的參數。

其實全部用 INT8 就有 50%，這個 case 的限制在於 SVD 要貢獻至少 20%。所以 SVD 只做到剛好過門檻，其他層用幾乎無損的 INT8 或 FP16，避免整體壓縮率超過 50%。

PPL 增加了 7.2，比 Case 1、2 只靠量化時的 0.4 到 1.9 多很多。我推測主要來自低秩截斷，因為 INT8 幾乎不影響 PPL，但沒有單獨量測。

down_proj 的輸入有很極端的 outlier channel，最大值和中位數差約 7000 倍，所以權重誤差和輸出誤差差很多，一般的 SVD 不適合，必須做 whitening。實作時也因為這些 outlier，fp16 累加 Hessian 時一般 channel 會 underflow，導致 Cholesky 失敗。改成每個 channel 分別縮放後就解決了，和 fp64 結果的相對誤差約 1e-4。

Case 4：剪枝 ≥ 20%，Overall ≥ 85%，PPL < 50

Compression Strategy

每層刪掉 30% 的 MLP intermediate channel，也就是同時刪 gate/up_proj 的 row 和 down_proj 的 column。channel j 的重要度定為 $\|W_down[:, j]\|^2 \cdot H_jj$，代表它對輸出的能量。刪除後用最小平方法重新計算 down_proj，把被刪 channel 的貢獻補到保留的 channel 上，不需要 gradient 訓練：

$$W' = W_keep + W_rm \cdot H_rk \cdot H_kk^{-1}$$

剪枝完再對全部目標層做 GPTQ INT3 g512 加 MSE clipping。

Result

剪枝率 22.20%，整體壓縮率 85.23%，PPL 18.33。

Analysis

85% 代表平均只能用 2.4 bits。非結構化或 2:4 的稀疏需要額外存 mask 或 index，在這麼緊的預算下不划算；結構化剪枝讓矩陣真的變小，沒有額外成本。剩下 77.8% 的參數乘上 3.037 bits 約 2.36 bits，對應 85.2%，和實際結果一致。

和 Case 2 相比，同樣是 INT3 g512，多剪掉 22% 的參數，PPL 從 15.49 升到 18.33。

總結

Trade-off

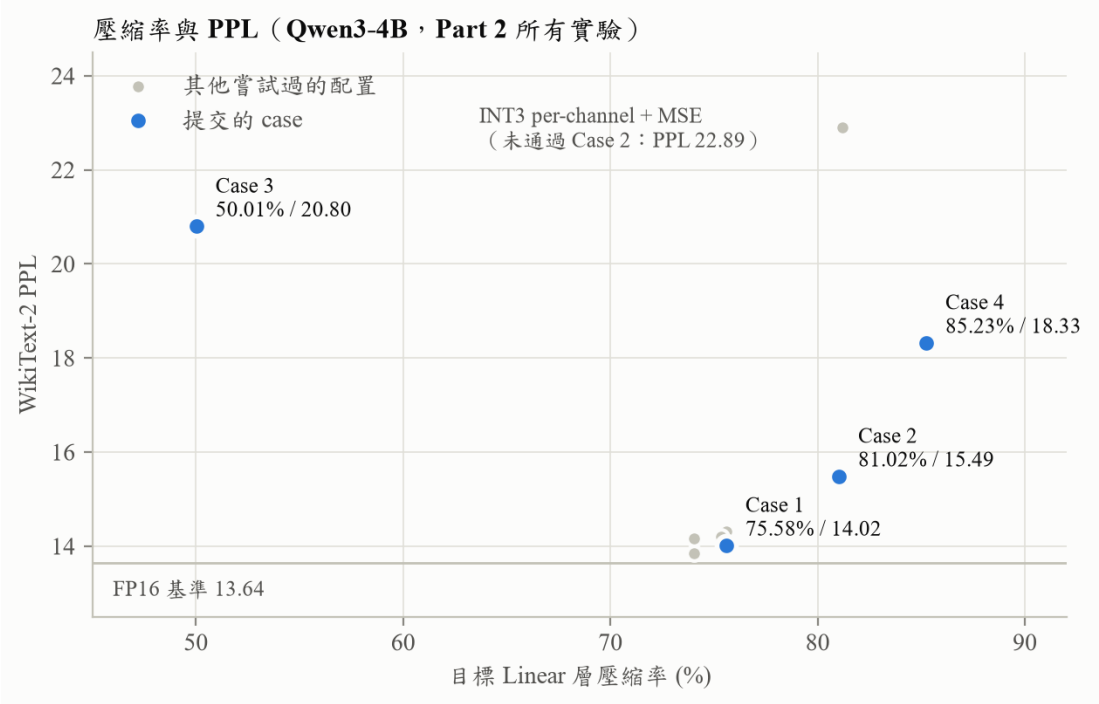


圖 4：壓縮率與 PPL（Part 2 所有實驗）

從 74% 到 81%，只靠量化時 PPL 只增加 0.2 到 1.9，代價很小。但到了 3-bit 以下就對 group 粒度非常敏感，per-channel 只比 g512 省 0.03 bits，PPL 卻從 15.49 變成 22.89。要省下同樣的空間，結構化剪枝（Case 4）的代價也比低秩分解（Case 3）小。

敏感層

以全部 INT4 g128 加 MSE（PPL 13.84）為基準，每次把一種 projection 降成 INT3 g128，結果如圖 5。gate_proj 和 down_proj 最不敏感，up_proj 和 q/o_proj 每個參數造成的 PPL 增加大約是它們的兩倍。

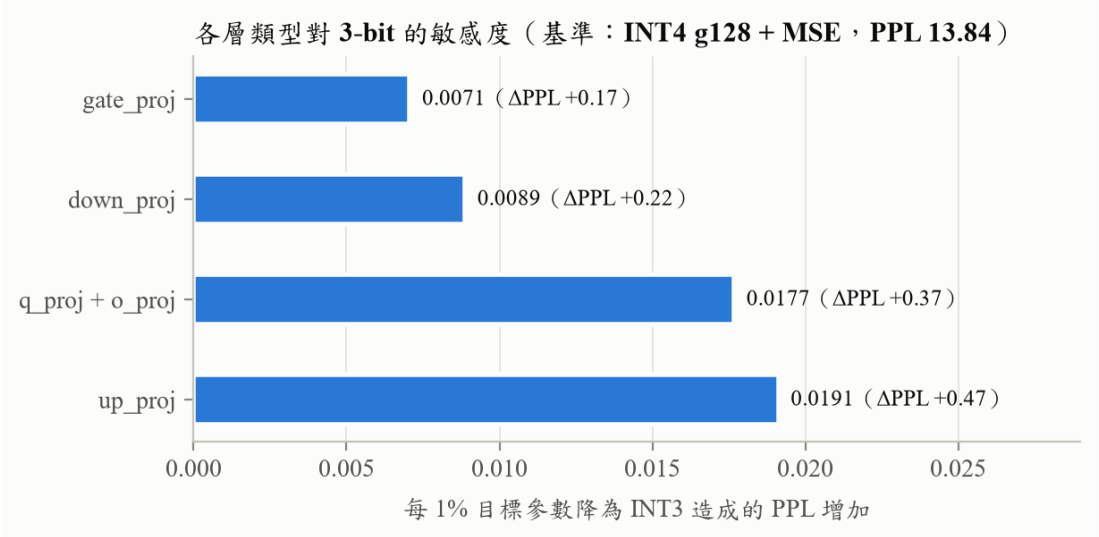


圖 5：各層類型對 3-bit 的敏感度

策略差異

Case 1、2 只靠量化，差別在混合精度和 group 大小。Case 3 受限於 SVD 至少 20% 的條件。Case 4 用結構化剪枝多換到約 4% 的壓縮率。

量化時有兩件事最有幫助。第一是 GPTQ，它的輸出誤差大約只有直接 round 的四分之一。第二是 MSE clipping，在 3-bit per-channel 時能讓誤差減少 56%。

限制

這次用的是 fake quantization，沒有真正的低 bit kernel，所以推論不會變快。混合精度只做到「層的類型」，沒有逐層調整。校正資料和測試資料都來自 WikiText-2，換成其他資料時效果可能較差。

結論

我認為最有效的方法是 GPTQ 加 MSE clipping 的 group-wise 量化。壓縮率要求越高，越應該先調 group 大小和混合精度，其次才是結構化剪枝，低秩分解的代價最高。這次最大的收穫是學到要先把 scale 和 zero point 的成本算清楚：全 INT4 過不了 75%、INT3 g128 過不了 81%，都是因為這些額外的 bits。