Lab 2 Part 3 報告：Calibration-Free Quantization

學號：315605019　　日期：2026-10-25

Method

我重現的是 AdaptQuant，方法本身不再介紹，以下只說明實作上的選擇。

量化範圍是 36 層、每層 7 個 Linear 的權重和輸入 activation；lm_head 和 attention 裡的 QK^T、PV 維持 fp16。T4 不支援 MX 格式，所以用 fake quantization，量化後馬上反量化回 fp16。

權重的 tile 是 16 個輸出 row × 32 個輸入 column，activation 的 tile 是 16 個 token × 32 個 channel，每 32 個元素共用一個 E8M0 scale。每個 tile 計算 stat = log2(amax / rms)，小於 t1 用 MXFP4，介於 t1 和 t2 之間用 MXFP6，大於 t2 用 MXFP8。

門檻用 `derive.py` 依論文的 Algorithm 1 推導，參考模型是 Llama-3.1-8B，語料是 WikiText-2 train 的前 2048 個 token。條件設為每一層的 SQNR 都不低於 NVFP4（slack s = 0），搜尋範圍 0 到 4.5、間隔 0.02，沒有使用論文的 bit target $b^\star$。NVFP4 參考使用 16 元素 block、E4M3 scale 加上 per-tensor FP32 scale。

這樣做是 calibration-free 的：量化 Qwen3-4B 時沒有讓任何資料通過模型，14 個門檻都是在 Llama-3.1-8B 上算好的常數，和論文的流程相同。

Result

最終 PPL 為 14.20（FP16 為 13.64），權重平均 5.29 bits / element，加上每個 tile 的格式標記是 5.37。對照組如下表與圖 1，所有方法都同時量化權重和 activation。

方法	PPL	權重 bits	論文 PPL
FP16	13.64	16	13.66
MXFP6	13.92	6.25	–
NVFP4	13.93	4.5	13.96
AdaptQuant	**14.20**	**5.29**	13.98（5.14 bits）
MXFP4	18.64	4.25	18.20

在 Qwen3-4B 上，權重 tile 有 47.8% 用 MXFP4、52.2% 用 MXFP6，沒有用到 MXFP8。

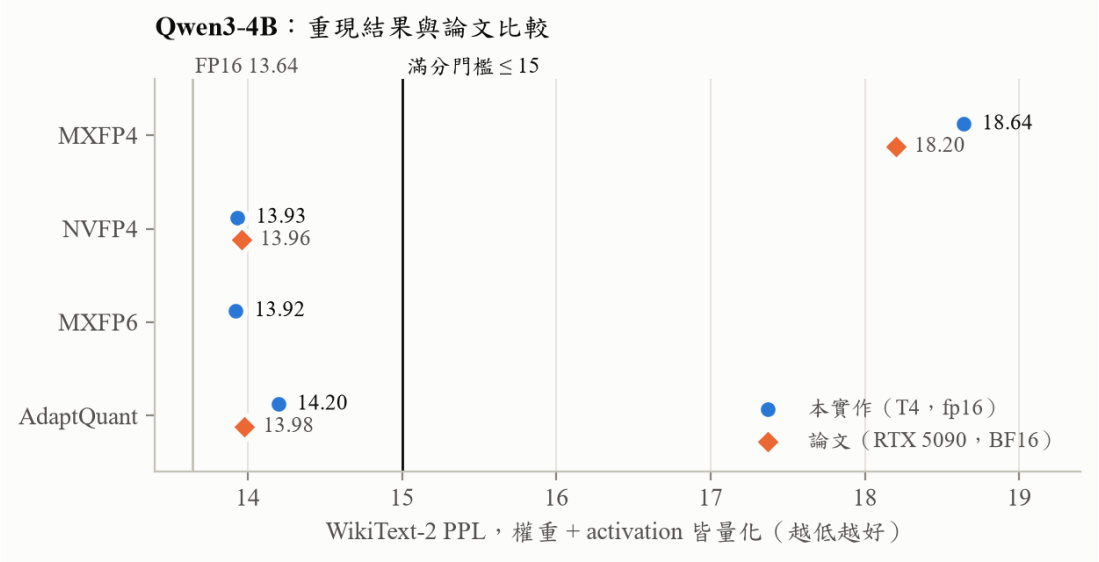


圖 1：Qwen3-4B 重現結果與論文比較

Observation and Discussion

推導出的門檻

各 projection 的門檻和 MXFP6 比例如下表與圖 2，套用到 Qwen3-4B 後權重的 stat 分布見圖 3。

projection	權重 t1	權重 FP6	act t1	act FP6
q_proj	1.84	45%	2.18	66%
k_proj	1.82	54%	2.06	73%
v_proj	1.78	44%	2.26	61%
o_proj	1.74	48%	2.28	62%
gate_proj	1.80	58%	1.80	58%
up_proj	1.74	46%	1.80	58%
down_proj	1.74	48%	2.54	67%

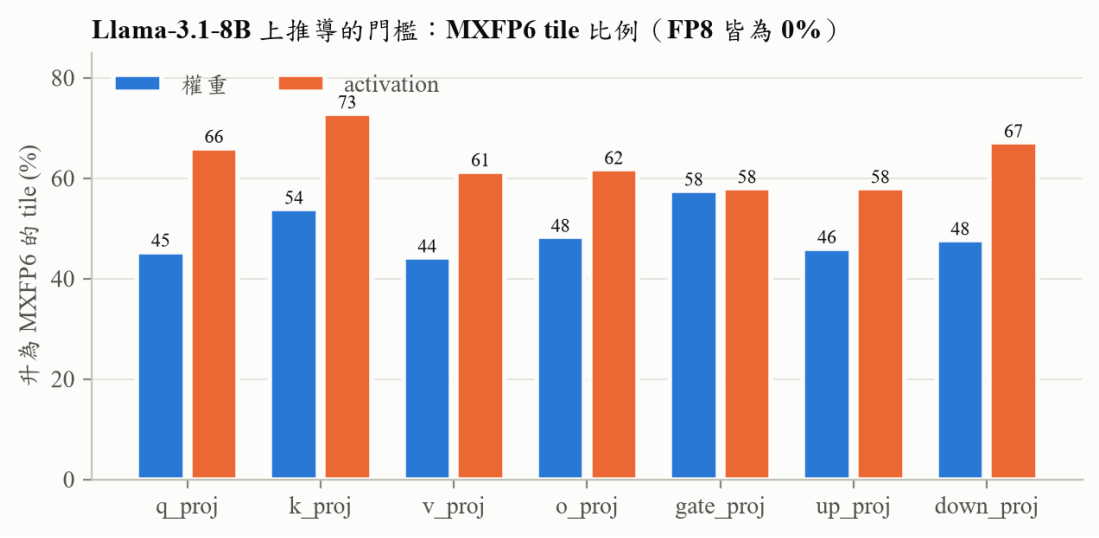


圖 2：Llama-3.1-8B 上推導的門檻對應的 MXFP6 tile 比例

所有 t2 都落在上限，也就是 FP8 從來沒被選到，和論文一致。activation 的 FP6 比例比權重高，也符合論文附錄 A 的觀察。每種 projection 對 NVFP4 的 SQNR 差距最少只有 0.01 到 0.3 dB，代表門檻是由最難量化的那一層決定的。套到 Qwen3-4B 後，權重的 FP6 比例是 52%，落在 Llama 上 44% 到 58% 的範圍內。

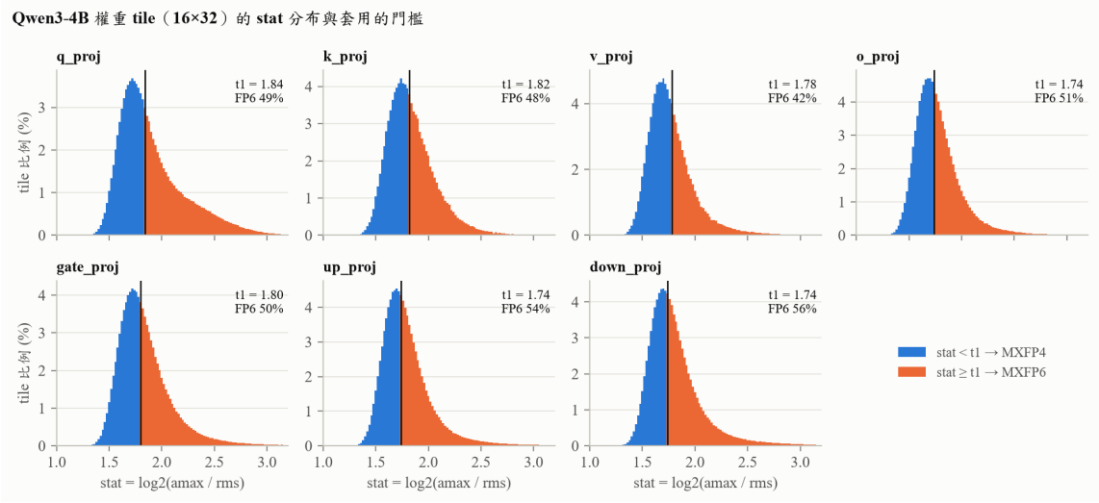


圖 3：Qwen3-4B 權重 tile（16×32）的 stat 分布與套用的門檻

對模型品質的影響

和全部 MXFP4 相比，AdaptQuant 只多用約 1 bit，PPL 就從 18.64 降到 14.20，接近 NVFP4 和 MXFP6（圖 4）。這表示 MXFP4 的誤差主要來自少數 stat 高的 tile，只要把這些 tile 改成 FP6，就能挽回大部分的精度。

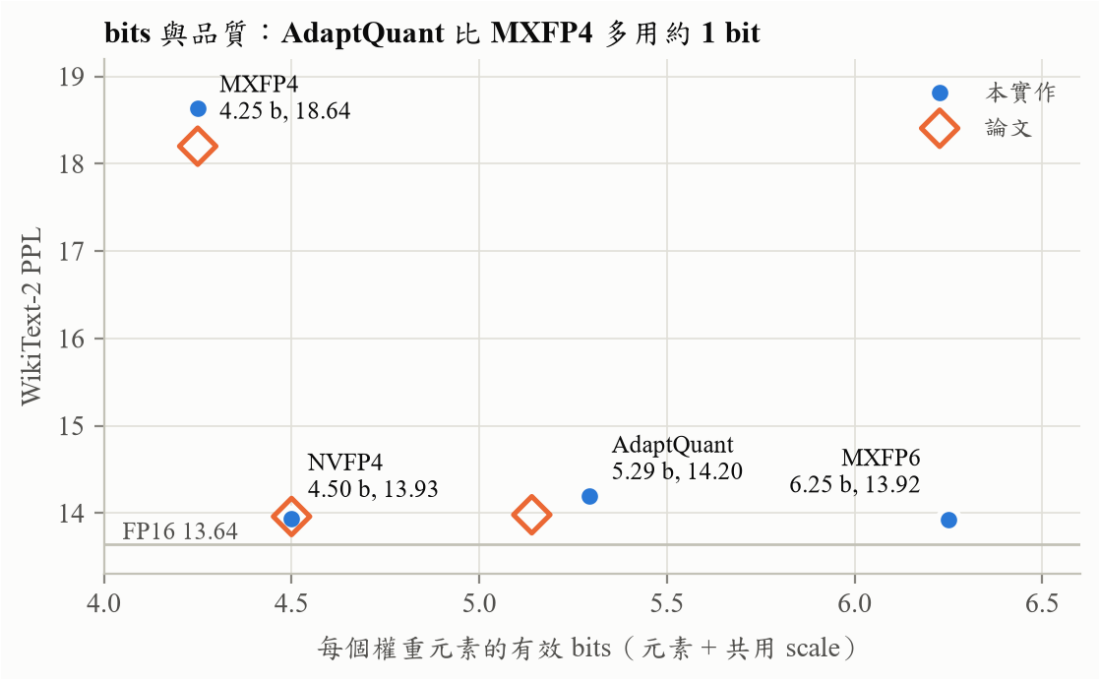


圖 4：權重 bits 與 PPL 的關係

相對 FP16 的退化

PPL 比 FP16 高了 0.56。原因有三點：第一，仍有 47.8% 的權重 tile 是 MXFP4，而全 MXFP4 的 PPL 是 18.64，誤差很大。第二，activation 也被量化，而且它的 FP6 比例較高，表示比權重更難量化。第三，門檻的目標本來就是和 NVFP4 同等的 SQNR，而 NVFP4 自己的 PPL 是 13.93，所以設計上就接受這個程度的損失。

與論文差 0.22 的可能原因

1. 論文使用 BF16，我在 T4 上只能用 fp16。
2. 推導門檻用的 2048 個 token 不同，論文沒有說明用哪一段。
3. 論文可能有用 bit target $b^\star$，我用的是 $s = 0$。我的權重 bits（5.29）比論文（5.14）多，PPL 卻比較差，所以差異應該在 activation 端或推導資料。
4. NVFP4 的 per-tensor scale 取法不同，也會改變 SQNR 的條件。

實作困難

沒有 Blackwell GPU，只能用 fake quantization，所以沒有實際加速，也沒有省到記憶體。Llama-3.1-8B 的 fp16 權重約 16 GB，放不進 T4，推導時只好把模型放在 CPU，一次搬一層到 GPU 計算。

為了確認量化器寫對，我用 Gaussian 資料量 SQNR，結果比論文 Table 1 高約 1.5 dB，但 FP6 和 FP4 的差距（12.15 dB 對 11.98 dB）以及 FP8 和 FP6 接近這兩點都吻合。另外 NVFP4 的 PPL 和論文只差 0.03，可以當作交叉驗證。論文沒寫清楚的細節，例如權重 tile 的方向、NVFP4 的 per-tensor scale、activation 的 padding，都需要自己決定。

限制與改進

門檻是在別的模型上推導的，Qwen3 的分布不一樣，例如 down_proj 的輸入有極端 outlier，所以 SQNR 的保證不一定能完全轉移。之後可以改用 slack 或 $b^\star$ 來調整 bits 和精度的取捨，或讓權重和 activation 使用不同的 tile 形狀。另外，每個 tile 的格式標記會額外佔用 0.078 bits。